Predicción del puntaje global de la prueba Saber 11 a partir de variables socioeconómicas y del colegio: planteamiento del problema y análisis exploratorio

Andrés Giovanny Rubiano Muñoz "Andy Rubiano"
Maestría en Inteligencia Artificial, Facultad de Ingeniería
Universidad de La Salle
Bogotá, Colombia
arubiano67@unisalle.edu.co

***Resumen*—Este informe corresponde a la primera fase del Proyecto Integrador de Ciencia de Datos y plantea el problema de predecir el puntaje global de la prueba Saber 11 a partir de variables socioeconómicas del hogar, del colegio y del estudiante, formulado como una tarea de regresión. Se utiliza el conjunto público *Resultados únicos Saber 11* del ICFES, restringido al periodo 2022-4, extraído del Portal Nacional de Datos Abiertos y publicado en Kaggle como una copia congelada para garantizar la reproducibilidad. El análisis exploratorio revela que la mitad de las 1.065.888 filas publicadas por el portal son duplicados exactos, de modo que el conjunto de trabajo queda en 532.792 estudiantes, y verifica que el puntaje global es una función determinista de los puntajes por área, que por tanto se excluyen como variables explicativas. La variable objetivo tiene media de 250,1 y desviación de 51,8 puntos, con una distribución casi simétrica. Las asociaciones más fuertes corresponden a la educación de la madre ($\rho = 0{,}35$), la edad ($\rho = -0{,}32$), la educación del padre (0,32) y la tenencia de computador (0,30) e internet (0,28); la jornada del colegio separa 70 puntos entre la completa y la nocturna, los colegios no oficiales superan a los oficiales en 29 puntos y la brecha entre departamentos alcanza 64 puntos entre Bogotá y Chocó. Una regresión lineal exploratoria explica el 24,2 % de la varianza con un error absoluto medio de 36,5 puntos, cota que servirá de referencia para las fases de modelado. El informe concluye con doce decisiones de preparación de datos e ingeniería de variables derivadas de los hallazgos.**

***Index Terms*—Ciencia de datos, análisis exploratorio de datos, Saber 11, ICFES, regresión, datos abiertos, fuga de información, nivel socioeconómico.**

I. Introducción

La ciencia de datos es la disciplina que combina estadística, computación y conocimiento del dominio para extraer, a partir de datos observados, conclusiones que respalden decisiones. Un proyecto de ciencia de datos recorre un ciclo que comienza con la formulación de una pregunta, continúa con la obtención, descripción y exploración de los datos, sigue con la preparación y el modelado, y termina con la evaluación y la comunicación de los resultados [1], [2]. Este informe corresponde a la primera fase de ese ciclo, el planteamiento del problema y el análisis exploratorio de datos, cuyo propósito es entender la estructura, la calidad y las regularidades del conjunto antes de construir cualquier modelo [3].

El caso de estudio es la prueba Saber 11, el examen de Estado que presentan en Colombia los estudiantes que terminan la educación media y cuyo puntaje global condiciona el acceso a la educación superior, a programas de becas y a los cupos de las universidades públicas [4]. El Instituto Colombiano para la Evaluación de la Educación (ICFES) publica, en el Portal Nacional de Datos Abiertos, un registro anónimo por estudiante que reúne el resultado de la prueba y un cuestionario sociodemográfico sobre su hogar y su colegio [5]. La literatura sobre los determinantes del rendimiento en Saber 11 ha documentado de forma consistente la asociación del puntaje con el nivel socioeconómico del hogar, la educación de los padres, la naturaleza y la jornada del colegio y la región [6], [7], lo que convierte al conjunto en un escenario adecuado para un problema de aprendizaje supervisado de regresión en el que la pregunta no es solo cuánto se puede predecir, sino qué variables, ajenas al esfuerzo individual del estudiante, explican esa predicción.

El trabajo se desarrolla en un cuaderno de Google Colab que descarga desde Kaggle una copia congelada del periodo 2022-4 del conjunto, lo describe, verifica su calidad, caracteriza la variable objetivo y examina su relación con las variables del estudiante, del hogar, del colegio y de la geografía. Una de las verificaciones es metodológicamente central, puesto que el puntaje global se construye como un promedio ponderado de los puntajes por área, estos últimos no pueden usarse como variables explicativas sin incurrir en una fuga de información [8], y el análisis lo comprueba sobre los datos. El informe está organizado de la siguiente manera, la Sección II plantea el problema, la pregunta de investigación, los objetivos y las hipótesis; la Sección III describe el conjunto de datos; la Sección IV expone la metodología del análisis exploratorio; la Sección V presenta los resultados y los primeros hallazgos, y la Sección VI recoge las conclusiones y las decisiones que orientan la fase de preparación y modelado.

II. Planteamiento del problema

II-A. Contexto

Cada año cerca de un millón de estudiantes presentan la prueba Saber 11 en el calendario A. El puntaje global que obtienen, en una escala de 0 a 500, resume su desempeño en cinco pruebas, lectura crítica, matemáticas, sociales y ciudadanas, ciencias naturales e inglés, y es el criterio que utilizan las universidades, el programa *Generación E* y otros mecanismos de acceso a la educación superior [4]. Dado que el ICFES recoge al momento de la inscripción un cuestionario sobre el hogar del estudiante y conoce las características del colegio en el que cursó la media, es posible preguntarse en qué medida ese puntaje es predecible a partir de información que existe *antes* de presentar el examen, y qué factores pesan más en esa predicción.

II-B. Pregunta de investigación

¿En qué medida las características socioeconómicas del hogar, las características del colegio y las características demográficas del estudiante permiten predecir el puntaje global de la prueba Saber 11, y cuáles de esas características tienen mayor peso?

II-C. Objetivos

II-C1. Objetivo general: Construir y evaluar un modelo de regresión que prediga el puntaje global de la prueba Saber 11 del periodo 2022-4 a partir de variables socioeconómicas, familiares y del colegio, e interpretar la contribución de cada grupo de variables.

II-C2. Objetivos específicos:

1. Describir el conjunto de datos *Resultados únicos Saber 11* (origen, licencia, variables, tamaño y calidad) y caracterizar la distribución de la variable objetivo.
2. Identificar, mediante análisis exploratorio, las variables con mayor asociación con el puntaje global y las que deben excluirse por fuga de información o por falta de valor predictivo.
3. Preparar los datos (tratamiento de valores faltantes, codificación de variables ordinales y nominales, ingeniería de variables) y establecer un modelo de referencia con su métrica inicial.
4. Entrenar y comparar al menos dos modelos adicionales al de referencia, ajustar sus hiperparámetros con validación cruzada y evaluarlos con métricas apropiadas para regresión (MAE, RMSE y R^2).
5. Interpretar el modelo final (importancia de variables y análisis de errores) y comunicar los resultados mediante visualizaciones, un informe técnico y una sustentación.

Este informe cubre los objetivos específicos 1 y 2, que corresponden a la Fase 1 del proyecto; los restantes se abordan en las fases 2, 3 y 4 [2].

II-D. Hipótesis de trabajo

- **H1.** El nivel socioeconómico del hogar, medido por el estrato, la educación de los padres y el acceso a internet y computador, es el grupo de variables con mayor asociación con el puntaje global.
- **H2.** Las características del colegio, su naturaleza oficial o privada, su área urbana o rural, su jornada y su calendario, aportan información adicional a la del hogar.
- **H3.** Existe una brecha regional, de modo que el departamento donde se ubica el colegio explica parte de la variación del puntaje incluso después de considerar el hogar y el colegio.

II-E. Alcance y restricciones

El problema se formula como una regresión sobre el puntaje global. Los puntajes por área y el nivel de desempeño en inglés no pueden usarse como variables explicativas, porque el puntaje global se calcula a partir de ellos y su inclusión constituiría una fuga de información [8]; la Sección V verifica esa relación sobre los datos. Se utiliza un único periodo, el 2022-4, para no mezclar escalas ni cuestionarios de distintos años y para mantener el volumen manejable en el entorno gratuito de Google Colab; la extensión a varios periodos queda como trabajo futuro. Por último, el análisis es correlacional, identifica asociaciones útiles para predecir y no relaciones causales.

III. Conjunto de datos

III-A. Origen y licencia

El conjunto *Resultados únicos Saber 11* es publicado por el Instituto Colombiano para la Evaluación de la Educación (ICFES) en el Portal Nacional de Datos Abiertos de Colombia, bajo el identificador `kgxf-xxbe` y con licencia Creative Commons Attribution-ShareAlike 4.0 (CC BY-SA 4.0), que permite su uso, redistribución y adaptación con atribución [5]. Reúne 7,1 millones de registros anónimos de las aplicaciones realizadas entre 2010 y 2022, uno por estudiante y periodo, con 51 columnas, y su última actualización data de agosto de 2023.

Para este proyecto se extrajo el periodo seleccionado y se publicó en Kaggle como una copia congelada en formato Parquet [9], redistribuida con la misma licencia, como lo exige CC BY-SA 4.0. Es la fuente que consume el cuaderno; no modifica ningún valor respecto del portal.

III-B. Periodo seleccionado y tamaño

Se trabaja con el periodo 2022-4, correspondiente a la aplicación del calendario A del segundo semestre de 2022, que es la que presenta la gran mayoría de colegios del país y el periodo más reciente y numeroso del conjunto. Contiene 1.065.888 filas, que ocupan 560 MB en CSV y 31,5 MB en Parquet; como se muestra en la Sección V, la mitad de ellas son duplicados exactos y el conjunto de trabajo queda en 532.792 estudiantes. La Tabla I resume sus características.

UNIVERSIDAD DE LA SALLE

Tabla I
RESUMEN DEL CONJUNTO DE DATOS

Aspecto	Valor
Fuente original	datos.gov.co, conjunto `kgxf-xxbe`
Copia utilizada	Kaggle, `andyrubiano/saber-11-resultados-2022-4`
Publicador	ICFES
Licencia	CC BY-SA 4.0
Periodo	2022-4 (calendario A, segundo semestre)
Filas publicadas	1.065.888
Filas únicas	532.792
Columnas	51
Variable objetivo	`punt_global` (0 a 500)
Tamaño en disco	31,5 MB (Parquet); 560 MB en CSV
Tamaño en memoria	131 MB (tipos categóricos)

III-C. Variables

Las 51 columnas se agrupan en cinco bloques según su prefijo, descritos en la Tabla II. Todas llegan como texto; en el cuaderno las categóricas se leen como `category`, los puntajes como numéricos y los identificadores como cadena.

Tabla II
BLOQUES DE VARIABLES DEL CONJUNTO

Bloque	Contenido
Identificación (5)	Periodo, identificador anónimo (`estu_consecutivo`), tipo de documento, condición del evaluado y estado del resultado.
Colegio, `cole_*` (17)	Códigos DANE e ICFES, nombres del establecimiento y la sede, naturaleza (oficial o no oficial), área (urbana o rural), calendario, carácter (académico o técnico), jornada, género de la población, bilingüismo y ubicación (departamento y municipio).
Estudiante, `estu_*` (13)	Género, fecha de nacimiento, nacionalidad, lugar de residencia, lugar de presentación de la prueba y privación de la libertad.
Hogar, `fami_*` (9)	Estrato de la vivienda, máximo nivel educativo de la madre y del padre, personas y cuartos del hogar y tenencia de internet, computador, automóvil y lavadora; provienen del cuestionario que el estudiante diligencia al inscribirse.
Resultados (7)	Puntaje en lectura crítica, matemáticas, sociales y ciudadanas, ciencias naturales e inglés (0 a 100), nivel de desempeño en inglés y puntaje global (0 a 500).

La variable objetivo es el puntaje global. Las variables explicativas candidatas son las de los bloques de estudiante, hogar y colegio, más el departamento y el municipio del colegio; los resultados por área se excluyen por la razón que se verifica en la Sección V.

IV. METODOLOGÍA

El análisis se realizó en un cuaderno de Google Colab cuyos segmentos de código se reproducen a lo largo de este informe en el mismo orden en que se ejecutan, puesto que cada paso depende del anterior, iniciando con la preparación del entorno, siguiendo con la descarga y verificación del conjunto, la depuración de duplicados, el tratamiento de los valores faltantes y la conversión de tipos, la caracterización de la variable objetivo y, por último, el examen de su relación con cada grupo de variables explicativas. El enfoque sigue la lógica del análisis exploratorio de datos de Tukey, mirar los datos antes de modelarlos para descubrir su estructura y sus anomalías [3], dentro del marco de fases de CRISP-DM [1].

IV-A. Entorno de trabajo y reproducibilidad

El cuaderno utiliza únicamente librerías preinstaladas en Colab, *kagglehub* para descargar el conjunto de datos, *pandas* para la carga y agregación de datos [10], *matplotlib* y *seaborn* para las figuras [11], [12], *scipy* para la correlación de Spearman y *scikit-learn* para el ajuste lineal exploratorio [13]. Las rutas se resuelven respecto de la raíz del repositorio, de modo que las figuras se guardan en `assets/images/data/`, que es de donde las toma este informe.

```python
import os, sys, time, warnings
from pathlib import Path

import numpy as np
import pandas as pd
import matplotlib
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import seaborn as sns
import scipy
from scipy import stats

warnings.filterwarnings("ignore")
pd.set_option("display.max_columns", 60)
pd.set_option("display.width", 160)
pd.set_option("display.float_format", "{:,.2f}".format)

print("pandas:", pd.__version__, "| numpy:", np.__version__, "| matplotlib:", matplotlib.__version__,
      "| seaborn:", sns.__version__, "| scipy:", scipy.__version__)

IN_COLAB = "google.colab" in sys.modules

def find_project_root(start=Path.cwd()):
    """Sube por el árbol de carpetas hasta encontrar la raíz del repositorio (README.md + notebooks/)."""
    for candidate in [start, *start.parents]:
        if (candidate / "README.md").exists() and (candidate / "notebooks").is_dir():
            return candidate
    return start

PROJECT_ROOT = Path("/content/saber11-project") if IN_COLAB else find_project_root()
FIG_DIR = PROJECT_ROOT / "assets" / "images" / "data"
FIG_DIR.mkdir(parents=True, exist_ok=True)

print(f"Entorno : {'Google Colab' if IN_COLAB else 'local'}")
print(f"Raíz del proyecto: {PROJECT_ROOT}")
```

Luego se fija la identidad gráfica, un azul para la variable objetivo y las series principales, un naranja para contrastes y un tono neutro para las descripciones del conjunto, y la semilla global `RANDOM_STATE = 42`, que gobierna el único muestreo del cuaderno.

```python
C_BASE, C_ACCENT, C_NEU = "#2a78d6", "#eb6834", "#5B7C99"
TINTA, GRIS = "#0b0b0b", "#52514e"
PALETTE = [C_BASE, C_ACCENT, "#2CA02C", "#9467BD", "#8C564B", "#E377C2", "#7F7F7F", "#BCBD22"]
```

```
CMAP_SEQ = "Blues"

sns.set_style("whitegrid")
sns.set_palette(PALETTE)
plt.rcParams.update({
    "figure.dpi": 110, "savefig.dpi": 110,
    "figure.facecolor": "white", "axes.facecolor": "white",
    "axes.edgecolor": "#d9d8d3", "axes.labelcolor": GRIS,
    "axes.spines.top": False, "axes.spines.right": False,
    "text.color": TINTA, "xtick.color": GRIS, "ytick.color": GRIS,
    "font.size": 10, "axes.titlesize": 12, "axes.titleweight": "bold",
    "axes.titlelocation": "left", "axes.titlepad": 12,
    "grid.color": "#eeede9", "grid.linewidth": 0.8,
})

RANDOM_STATE = 42
np.random.seed(RANDOM_STATE)

def save_fig(fig, name):
    """Guarda la figura en assets/images/data/<name>.png (de ahí la toma el informe)."""
    path = FIG_DIR / f"{name}.png"
    fig.savefig(path, bbox_inches="tight")
    print(f"Figura guardada: {path.relative_to(PROJECT_ROOT) if path.is_relative_to(PROJECT_ROOT) else path}")
```

IV-B. Descarga y carga del conjunto

El periodo 2022-4 se extrajo del Portal Nacional de Datos Abiertos mediante su API, con un filtro por periodo y un orden fijo por identificador, y se publicó en Kaggle como el dataset *Saber 11 Colombia - Resultados 2022-4* [9], con la misma licencia y atribución al ICFES. La copia conserva todas las filas y columnas tal como las entrega el portal; el único cambio es el formato, de CSV (560 MB) a Parquet (31,5 MB), que además guarda el tipo de cada columna: las categóricas como `category`, los puntajes como `float32` y los identificadores como cadena. Publicar una copia congelada hace el análisis reproducible aunque el portal actualice sus datos, y reduce la carga del cuaderno a unos segundos. La celda descarga únicamente el archivo Parquet con *kagglehub*, que no requiere cuenta de Kaggle para un dataset público, y lo lee con *pandas*.

```
import kagglehub

KAGGLE_DATASET = "andyrubiano/saber-11-resultados-2022-4"
PARQUET_FILE = "saber11_20224.parquet"
PERIODO = "20224"

SCORE_COLS = ["punt_matematicas", "punt_lectura_critica", "punt_sociales_ciudadanas",
              "punt_c_naturales", "punt_ingles", "punt_global"]
ID_COLS = ["estu_consecutivo", "estu_fechanacimiento"]

t0 = time.time()
parquet_path = kagglehub.dataset_download(KAGGLE_DATASET, path=PARQUET_FILE)
df = pd.read_parquet(parquet_path)

print(f"Fuente : Kaggle ·{KAGGLE_DATASET} ·{PARQUET_FILE}")
print(f"Origen : ICFES ·datos.gov.co, conjunto kgxf-xxbe, periodo 2022-4 (CC BY-SA 4.0)")
print(f"Registros: {len(df):,} | Columnas: {df.shape[1]} | "
      f"Memoria: {df.memory_usage(deep=True).sum() / 1e6:,.0f} MB | Carga: {time.time() - t0:,.1f} s")
df.head(3)
```

La estructura del conjunto se verifica columna por columna, tipo, cantidad de valores no nulos, porcentaje de faltantes, cardinalidad y un valor de ejemplo, que es la base del diccionario de variables de la Sección III.

```
estructura = pd.DataFrame({
    "tipo": df.dtypes.astype(str),
    "no_nulos": df.notna().sum(),
    "pct_nulos": (df.isna().mean() * 100).round(2),
    "valores_unicos": df.nunique(),
    "ejemplo": df.iloc[0].astype(str).str.slice(0, 30),
})
estructura.index.name = "columna"
display(estructura)
```

IV-C. Calidad de los datos

Se cuentan los registros duplicados y se comprueba si el identificador `estu_consecutivo` es único; los duplicados exactos se eliminan y el resto del análisis se realiza sobre el conjunto depurado. Se identifican además las columnas constantes y las de muy poca variación, que no aportan información a un modelo, y se tabula la cardinalidad de cada variable categórica, que determina su codificación en la fase 2.

```
n_inicial = len(df)
duplicados = df.duplicated().sum()
print(f"Registros descargados : {n_inicial:,}")
print(f"Registros duplicados (fila completa) : {duplicados:,} ({duplicados / n_inicial * 100:.2f} %)")
print(f"Valores distintos de estu_consecutivo: {df['estu_consecutivo'].nunique():,}")

df = df.drop_duplicates().reset_index(drop=True)
repetidos = df["estu_consecutivo"].duplicated(keep=False).sum()
print()
print(f"Registros tras eliminar duplicados : {len(df):,}")
print(f"estu_consecutivo es único : {df['estu_consecutivo'].is_unique}"
      + ("" if repetidos == 0 else f" ({repetidos:,} filas comparten identificador con contenido distinto)"))

n_unique = df.nunique()
constantes = n_unique[n_unique <= 1].index.tolist()
print(f"\nColumnas constantes (1 valor) : {constantes}")

print("\nColumnas con muy poca variación (categoría dominante > 99 %):")
for col in df.columns.drop(SCORE_COLS + ID_COLS):
    share = df[col].value_counts(normalize=True, dropna=False).iloc[0]
    if share > 0.99 and col not in constantes:
        top = df[col].value_counts(dropna=False).index[0]
        print(f"  {col:<32} {str(top):<22} {share * 100:6.2f} %")

print("\nCardinalidad de las variables categóricas:")
card = n_unique.drop(SCORE_COLS + ID_COLS).sort_values(ascending=False)
display(card.to_frame("valores_unicos").T)
```

Los valores faltantes se cuantifican por columna y se examina si los del bloque `fami_*` ocurren juntos, lo que indicaría estudiantes que no diligenciaron el cuestionario, o de forma independiente; también se compara el puntaje de quienes no tienen cuestionario con el del resto, para saber si la ausencia es informativa.

```
faltantes = (df.isna().mean() * 100).round(2)
faltantes = faltantes[faltantes > 0].sort_values(
    ascending=True)

fig, ax = plt.subplots(figsize=(9, 0.42 * len(faltantes
    ) + 1.2))
bars = ax.barh(faltantes.index, faltantes.values, color
    =C_NEU)
ax.bar_label(bars, labels=[f"{v:.1f} %" for v in
    faltantes.values], padding=4, fontsize=9, color=
    GRIS)
ax.set_title("Porcentaje de valores faltantes por
    columna (solo columnas con faltantes)")
ax.set_xlabel("% de registros sin dato")
ax.set_xlim(0, faltantes.max() * 1.18)
ax.grid(axis="y", visible=False)
save_fig(fig, "missing_values")
plt.show()

fami_cols = [c for c in df.columns if c.startswith("
    fami_")]
sin_cuestionario = df[fami_cols].isna().all(axis=1)
algun_faltante = df[fami_cols].isna().any(axis=1)
print(f"Registros sin ningún dato del cuestionario (
    fami_* todo nulo): {sin_cuestionario.sum():,} "
    f"({sin_cuestionario.mean() * 100:.2f} %)")
print(f"Registros con al menos un fami_* faltante : {
    algun_faltante.sum():,} "
    f"({algun_faltante.mean() * 100:.2f} %)")
print(f"Registros con cuestionario completo : {(~
    algun_faltante).sum():,} "
    f"({(~algun_faltante).mean() * 100:.2f} %)")

comparacion = pd.DataFrame({
    "sin_cuestionario": df.loc[sin_cuestionario, "
        punt_global"].describe(),
    "con_cuestionario": df.loc[~sin_cuestionario, "
        punt_global"].describe(),
}).round(1)
display(comparacion.T)
```

Por último se convierte la fecha de nacimiento en la edad al momento de la prueba, tomando como referencia la fecha de aplicación del calendario A de 2022, y se fija el orden natural de las variables ordinales (estrato, educación de los padres, personas y cuartos del hogar, nivel de inglés), que `category` no conoce por sí misma.

```
FECHA_PRUEBA = pd.Timestamp("2022-09-04")
fecha_nac = pd.to_datetime(df["estu_fechanacimiento"],
    format="%d/%m/%Y", errors="coerce")
df["edad"] = ((FECHA_PRUEBA - fecha_nac).dt.days /
    365.25).round(1)
fuera_rango = (df["edad"] < 13) | (df["edad"] > 80)
print(f"Fechas no interpretables : {fecha_nac.isna().
    sum():,}")
print(f"Edades fuera de [13, 80] : {fuera_rango.sum()
    :,} →se marcan como faltantes")
df.loc[fuera_rango, "edad"] = np.nan

ORDEN = {
    "fami_estratovivienda": ["Sin Estrato", "Estrato 1",
        "Estrato 2", "Estrato 3",
                             "Estrato 4", "Estrato 5", "
                                 Estrato 6"],
    "fami_educacionmadre": ["Ninguno", "Primaria
        incompleta", "Primaria completa",
                            "Secundaria (Bachillerato)
                                incompleta", "Secundaria (
                                Bachillerato) completa",
                            "Técnica o tecnológica incompleta"
                                , "Técnica o tecnológica
                                completa",
                            "Educación profesional incompleta"
                                , "Educación profesional
                                completa",
                            "Postgrado", "No sabe", "No Aplica
                                "],
    "fami_personashogar": ["1 a 2", "3 a 4", "5 a 6", "7
        a 8", "9 o más"],
    "fami_cuartoshogar": ["Uno", "Dos", "Tres", "Cuatro"
        , "Cinco", "Seis o mas"],
    "desemp_ingles": ["A-", "A1", "A2", "B1", "B+"],
}
ORDEN["fami_educacionpadre"] = ORDEN["
    fami_educacionmadre"]

for col, orden in ORDEN.items():
    presentes = [o for o in orden if o in df[col].cat.
        categories]
    faltan = [c for c in df[col].cat.categories if c not
         in orden]
    if faltan:
        print(f" {col}: categorías no previstas en el
            orden →{faltan}")
    df[col] = df[col].cat.set_categories(presentes +
        faltan, ordered=True)

print("\nEdad al presentar la prueba:")
display(df["edad"].describe().round(1).to_frame().T)
```

IV-D. Variable objetivo

La distribución de `punt_global` se caracteriza con sus estadísticas descriptivas, su asimetría y curtosis, un histograma y un diagrama de caja. Luego se verifica la fórmula con la que el ICFES construye el puntaje global a partir de las cinco pruebas [4],

$$G = \text{round}\left(\frac{3\,LC + 3\,MAT + 3\,SOC + 3\,CN + 1\,ING}{13} \times 5 \right), \tag{1}$$

donde LC, MAT, SOC, CN e ING son los puntajes de lectura crítica, matemáticas, sociales y ciudadanas, ciencias naturales e inglés. Si la fórmula se cumple sobre los datos, los puntajes por área son componentes de la respuesta y no variables explicativas, y su inclusión en un modelo constituiría una fuga de información [8].

```
y = df["punt_global"]
desc = y.describe().round(1)
desc["asimetría"] = round(y.skew(), 3)
desc["curtosis"] = round(y.kurt(), 3)
display(desc.to_frame("punt_global").T)

fig, axes = plt.subplots(1, 2, figsize=(13, 4.2),
    gridspec_kw={"width_ratios": [3, 1]})
axes[0].hist(y.dropna(), bins=80, color=C_BASE, alpha
    =0.9, edgecolor="white", linewidth=0.3)
axes[0].axvline(y.mean(), color=C_ACCENT, linestyle="--
    ", linewidth=1.5, label=f"Media = {y.mean():.1f}")
axes[0].axvline(y.median(), color=TINTA, linestyle=":",
     linewidth=1.5, label=f"Mediana = {y.median():.1f}
    ")
axes[0].set_title(f"Distribución del puntaje global ·
    periodo {PERIODO} (n = {y.notna().sum():,})")
axes[0].set_xlabel("Puntaje global (0 a 500)")
axes[0].set_ylabel("Estudiantes")
axes[0].yaxis.set_major_formatter(mticker.FuncFormatter
    (lambda v, _: f"{v / 1000:.0f} k"))
axes[0].legend(frameon=False)
```

```
sns.boxplot(y=y, ax=axes[1], color=C_BASE, width=0.4, fliersize=1.5,
            flierprops={"markerfacecolor": GRIS, "markeredgecolor": "none", "alpha": 0.3})
axes[1].set_title("Diagrama de caja")
axes[1].set_ylabel("Puntaje global")
fig.tight_layout()
save_fig(fig, "target_distribution")
plt.show()

p = np.percentile(y.dropna(), [1, 5, 25, 50, 75, 95, 99])
print("Percentiles 1, 5, 25, 50, 75, 95, 99:", np.round(p, 1))
```

```
calc = ((3 * df["punt_lectura_critica"] + 3 * df["punt_matematicas"] + 3 * df["punt_sociales_ciudadanas"]
         + 3 * df["punt_c_naturales"] + 1 * df["punt_ingles"]) / 13 * 5)
diff = (df["punt_global"] - calc.round()).abs()
completos = calc.notna()
print(f"Registros con las cinco pruebas : {completos.sum():,} de {len(df):,}")
print(f"Coinciden exactamente con la fórmula: {(diff[completos] == 0).mean() * 100:.2f} %")
print(f"Diferencia absoluta máxima : {diff[completos].max():.0f} puntos")
print(f"Diferencia absoluta ≤1 punto : {(diff[completos] <= 1).mean() * 100:.2f} %")

corr_areas = df[SCORE_COLS].corr(method="pearson")["punt_global"].drop("punt_global").sort_values(ascending=False)
display(corr_areas.round(3).to_frame("correlación de Pearson con punt_global").T)
```

IV-E. Análisis bivariado por grupo de variables

Para cada variable categórica se calcula el tamaño, la media, la mediana y la desviación del puntaje global por categoría, y se grafica con diagramas de caja sin valores atípicos, de modo que la comparación entre grupos no quede dominada por los extremos. Dos funciones auxiliares, `resumen_por` y `caja_por`, encapsulan ese patrón y se reutilizan en las secciones de estudiante, hogar y colegio. La edad se agrupa en tramos, porque su relación con el puntaje no tiene por qué ser lineal.

```
def resumen_por(col, orden=None, min_n=0):
    """Tamaño, media, mediana y desviación del puntaje global por categoría de `col`."""
    tabla = (df.groupby(col, observed=True)["punt_global"]
             .agg(n="size", media="mean", mediana="median", desv="std").round(1))
    if orden is not None:
        tabla = tabla.reindex([o for o in orden if o in tabla.index])
    return tabla[tabla["n"] >= min_n]

def caja_por(ax, col, orden=None, titulo=None, color=C_BASE, rot=0, min_n=0):
    """Diagrama de caja del puntaje global por categoría, con el tamaño de cada grupo en el eje."""
    tabla = resumen_por(col, orden, min_n)
    sns.boxplot(data=df[df[col].isin(tabla.index)], x=col, y="punt_global", order=tabla.index,
                ax=ax, color=color, width=0.6, showfliers=False)
    ax.set_xticklabels([f"{c}\n(n = {n:,})" for c, n in zip(tabla.index, tabla["n"])], rotation=rot,
                       ha="right" if rot else "center", fontsize=8.5)
    ax.set_title(titulo or col)
    ax.set_xlabel("")
    ax.set_ylabel("Puntaje global")
    return tabla

df["edad_grupo"] = pd.cut(df["edad"], bins=[12, 15, 16, 17, 18, 20, 25, 80],
                          labels=["13-15", "16", "17", "18", "19-20", "21-25", "26+"],
                          right=True)

fig, axes = plt.subplots(1, 3, figsize=(15, 4.3), gridspec_kw={"width_ratios": [1, 2.2, 1.6]})
t_genero = caja_por(axes[0], "estu_genero", ["F", "M"], "Género del estudiante")
t_edad = caja_por(axes[1], "edad_grupo", None, "Edad al presentar la prueba (años)")
t_doc = caja_por(axes[2], "estu_tipodocumento", None, "Tipo de documento", min_n=1000)
fig.tight_layout()
save_fig(fig, "student_variables")
plt.show()

print("Género:"); display(t_genero.T)
print("Edad:"); display(t_edad.T)
print("Tipo de documento (grupos con n ≥1.000):"); display(t_doc.T)
```

```
fig, axes = plt.subplots(3, 1, figsize=(13, 13))
t_estrato = caja_por(axes[0], "fami_estratovivienda", ORDEN["fami_estratovivienda"], "Estrato de la vivienda")
t_madre = caja_por(axes[1], "fami_educacionmadre", ORDEN["fami_educacionmadre"],
                   "Máximo nivel educativo de la madre", rot=25)
t_padre = caja_por(axes[2], "fami_educacionpadre", ORDEN["fami_educacionpadre"],
                   "Máximo nivel educativo del padre", rot=25)
fig.tight_layout()
save_fig(fig, "family_ordinal")
plt.show()

print("Estrato:"); display(t_estrato.T)
print("Educación de la madre:"); display(t_madre.T)
print("Educación del padre:"); display(t_padre.T)
```

Para las variables binarias del hogar se compara la media del puntaje entre quienes tienen y no tienen cada bien, y se reporta la diferencia en puntos.

```
BIENES = ["fami_tieneinternet", "fami_tienecomputador", "fami_tieneautomovil", "fami_tienelavadora"]
filas = []
for col in BIENES:
    g = df.groupby(col, observed=True)["punt_global"].agg(["size", "mean"])
    filas.append({"variable": col.replace("fami_tiene", "tiene_"),
                  "n_si": int(g.loc["Si", "size"]), "n_no": int(g.loc["No", "size"]),
                  "media_si": round(g.loc["Si", "mean"], 1), "media_no": round(g.loc["No", "mean"], 1),
                  "diferencia": round(g.loc["Si", "mean"] - g.loc["No", "mean"], 1)})
bienes = pd.DataFrame(filas).set_index("variable").sort_values("diferencia", ascending=False)
display(bienes)

fig, axes = plt.subplots(1, 3, figsize=(15, 4.3), gridspec_kw={"width_ratios": [1.3, 1, 1]})
bars = axes[0].barh(bienes.index, bienes["diferencia"], color=C_BASE)
axes[0].bar_label(bars, labels=[f"+{v:.1f}" for v in bienes["diferencia"]], padding=4, fontsize=9)
axes[0].set_title("Diferencia de media (tiene −no tiene), en puntos")
axes[0].set_xlabel("Puntos de puntaje global")
```

```
axes[0].set_xlim(0, bienes["diferencia"].max() * 1.2)
axes[0].grid(axis="y", visible=False)
t_personas = caja_por(axes[1], "fami_personashogar", ORDEN["fami_personashogar"], "Personas en el hogar")
t_cuartos = caja_por(axes[2], "fami_cuartoshogar", ORDEN["fami_cuartoshogar"], "Cuartos del hogar")
fig.tight_layout()
save_fig(fig, "family_binary")
plt.show()

print("Personas en el hogar:"); display(t_personas.T)
print("Cuartos del hogar:"); display(t_cuartos.T)
```

```
fig, axes = plt.subplots(2, 4, figsize=(17, 8.5))
axes = axes.ravel()
t_nat = caja_por(axes[0], "cole_naturaleza", ["OFICIAL", "NO OFICIAL"], "Naturaleza del colegio")
t_area = caja_por(axes[1], "cole_area_ubicacion", ["URBANO", "RURAL"], "Área de ubicación")
t_cal = caja_por(axes[2], "cole_calendario", ["A", "B", "OTRO"], "Calendario")
t_bil = caja_por(axes[3], "cole_bilingue", ["N", "S"], "Colegio bilingüe")
t_jor = caja_por(axes[4], "cole_jornada", None, "Jornada", rot=25, min_n=1000)
t_car = caja_por(axes[5], "cole_caracter", None, "Carácter", rot=25, min_n=1000)
t_gen = caja_por(axes[6], "cole_genero", ["MIXTO", "FEMENINO", "MASCULINO"], "Género del colegio", rot=25)
t_sede = caja_por(axes[7], "cole_sede_principal", ["S", "N"], "Es sede principal")
fig.tight_layout()
save_fig(fig, "school_variables")
plt.show()

for nombre, tabla in [("Naturaleza", t_nat), ("Área", t_area), ("Calendario", t_cal), ("Bilingüe", t_bil),
                      ("Jornada", t_jor), ("Carácter", t_car), ("Género del colegio", t_gen)]:
    print(f"{nombre}:"); display(tabla.T)
```

Como naturaleza y área se cruzan (la mayoría de colegios rurales son oficiales), se tabula el puntaje medio en las cuatro combinaciones.

```
cruce = df.pivot_table(index="cole_naturaleza", columns="cole_area_ubicacion", values="punt_global",
                       aggfunc=["mean", "size"], observed=True)
cruce.columns = [f"{a}_{b}" for a, b in cruce.columns]
display(cruce.round(1))
```

Para la geografía se calcula el puntaje medio por departamento del colegio, se ordena y se contrasta con la media nacional.

```
geo = (df.groupby("cole_depto_ubicacion", observed=True)["punt_global"]
       .agg(n="size", media="mean", mediana="median", desv="std").round(1)
       .sort_values("media", ascending=True))
display(geo.sort_values("media", ascending=False).T)

fig, ax = plt.subplots(figsize=(10, 0.3 * len(geo) + 1.5))
colores = [C_ACCENT if m < df["punt_global"].mean() else C_BASE for m in geo["media"]]
bars = ax.barh(geo.index, geo["media"], color=colores)
ax.bar_label(bars, labels=[f"{m:.0f}  (n = {n:,})" for m, n in zip(geo["media"], geo["n"])],
             padding=4, fontsize=8, color=GRIS)
ax.axvline(df["punt_global"].mean(), color=TINTA, linestyle="--", linewidth=1,
           label=f"Media nacional = {df['punt_global'].mean():.1f}")
ax.set_xlim(geo["media"].min() - 20, geo["media"].max() + 60)
ax.set_title("Puntaje global medio por departamento del colegio")
ax.set_xlabel("Puntaje global medio")
ax.tick_params(axis="y", labelsize=8.5)
ax.grid(axis="x", visible=False)
ax.legend(frameon=False, loc="lower right")
save_fig(fig, "geography")
plt.show()

print(f"Brecha entre el departamento con mayor y menor media: "
      f"{geo['media'].max() - geo['media'].min():.1f} puntos "
      f"({geo['media'].idxmax()} vs. {geo['media'].idxmin()})")
```

IV-F. Correlaciones y ajuste lineal exploratorio

Las variables ordinales se codifican con enteros que respetan su orden, estrato de 0 a 6 y nivel educativo de 0 a 9 (las categorías *No sabe* y *No Aplica* se tratan como faltantes), las binarias con 0 y 1, y se calcula la correlación de Spearman [14],

$$\rho = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n\,(n^2 - 1)}, \tag{2}$$

donde d_i es la diferencia entre los rangos de las dos variables para la observación i. Se eligió Spearman en lugar de Pearson porque mide asociaciones monótonas, no solo lineales, y es apropiada para variables ordinales. La matriz incluye los puntajes por área para documentar el contraste entre una variable explicativa legítima y una que forma parte de la respuesta.

```
EDU_NIVEL = {"Ninguno": 0, "Primaria incompleta": 1, "Primaria completa": 2,
             "Secundaria (Bachillerato) incompleta": 3, "Secundaria (Bachillerato) completa": 4,
             "Técnica o tecnológica incompleta": 5, "Técnica o tecnológica completa": 6,
             "Educación profesional incompleta": 7, "Educación profesional completa": 8, "Postgrado": 9}
ESTRATO_NIVEL = {"Sin Estrato": 0, **{f"Estrato {i}": i for i in range(1, 7)}}
PERSONAS_NIVEL = {"1 a 2": 1, "3 a 4": 2, "5 a 6": 3, "7 a 8": 4, "9 o más": 5}
CUARTOS_NIVEL = {"Uno": 1, "Dos": 2, "Tres": 3, "Cuatro": 4, "Cinco": 5, "Seis o mas": 6}

def binaria(col, positivo):
    return df[col].map(lambda v: np.nan if pd.isna(v) else float(v == positivo))

num = pd.DataFrame({
    "estrato": df["fami_estratovivienda"].astype(object).map(ESTRATO_NIVEL),
    "educ_madre": df["fami_educacionmadre"].astype(object).map(EDU_NIVEL),
    "educ_padre": df["fami_educacionpadre"].astype(object).map(EDU_NIVEL),
    "personas_hogar": df["fami_personashogar"].astype(object).map(PERSONAS_NIVEL),
    "cuartos_hogar": df["fami_cuartoshogar"].astype(object).map(CUARTOS_NIVEL),
    "tiene_internet": binaria("fami_tieneinternet", "Si"),
    "tiene_computador": binaria("fami_tienecomputador", "Si"),
```

```
    "tiene_automovil": binaria("fami_tieneautomovil", "Si"),
    "tiene_lavadora": binaria("fami_tienelavadora", "Si"),
    "colegio_no_oficial": binaria("cole_naturaleza", "NO OFICIAL"),
    "colegio_urbano": binaria("cole_area_ubicacion", "URBANO"),
    "colegio_bilingue": binaria("cole_bilingue", "S"),
    "calendario_B": binaria("cole_calendario", "B"),
    "jornada_completa_unica": df["cole_jornada"].isin(["COMPLETA", "UNICA"]).astype(float),
    "genero_F": binaria("estu_genero", "F"),
    "edad": df["edad"],
    "punt_lectura_critica": df["punt_lectura_critica"],
    "punt_matematicas": df["punt_matematicas"],
    "punt_sociales_ciudadanas": df["punt_sociales_ciudadanas"],
    "punt_c_naturales": df["punt_c_naturales"],
    "punt_ingles": df["punt_ingles"],
    "punt_global": df["punt_global"],
})

corr = num.corr(method="spearman")
ranking = corr["punt_global"].drop("punt_global").sort_values(key=np.abs, ascending=False)
print("Correlación de Spearman con punt_global (ordenada por magnitud):")
display(ranking.round(3).to_frame("rho").T)

fig, ax = plt.subplots(figsize=(13, 11))
mask = np.triu(np.ones_like(corr, dtype=bool), k=1)
sns.heatmap(corr, mask=mask, cmap="RdBu_r", vmin=-1, vmax=1, center=0, annot=True, fmt=".2f",
            annot_kws={"size": 7}, square=True, linewidths=0.4, cbar_kws={"shrink": 0.6}, ax=ax)
ax.set_title("Matriz de correlación de Spearman entre variables candidatas, puntajes por área y puntaje global")
ax.tick_params(axis="both", labelsize=8.5)
save_fig(fig, "correlation_matrix")
plt.show()
```

Finalmente se ajusta una regresión lineal exploratoria sobre las variables codificadas, excluidos los puntajes por área, con una muestra aleatoria de 200.000 filas completas y una partición 80/20. No es el modelo de referencia de la fase 2, que se construirá con la limpieza completa y la partición definitiva, sino una cota rápida de cuánta varianza del puntaje explican las variables candidatas en conjunto, medida con el coeficiente de determinación R^2 y el error absoluto medio (MAE).

```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_absolute_error, r2_score

PREDICTORAS = [c for c in num.columns if not c.startswith("punt_")]
muestra = num[PREDICTORAS + ["punt_global"]].dropna().sample(200_000, random_state=RANDOM_STATE)
X_tr, X_te, y_tr, y_te = train_test_split(muestra[PREDICTORAS], muestra["punt_global"],
                                          test_size=0.2, random_state=RANDOM_STATE)
lineal = LinearRegression().fit(X_tr, y_tr)
pred = lineal.predict(X_te)
print(f"Filas completas usadas: {len(muestra):,} (80 % entrenamiento / 20 % prueba)")
print(f"R² en prueba : {r2_score(y_te, pred):.3f}")
print(f"MAE en prueba: {mean_absolute_error(y_te, pred):.1f} puntos "
    f"(desviación del puntaje: {y_te.std():.1f}; MAE de predecir la media: "
    f"{mean_absolute_error(y_te, np.full_like(y_te, y_tr.mean())):.1f})")

coefs = pd.Series(lineal.coef_, index=PREDICTORAS).sort_values(key=np.abs, ascending=False)
display(coefs.round(2).to_frame("coeficiente (puntos por unidad)").T)
```

V. Resultados

V-A. *Calidad de los datos*

La primera verificación resultó decisiva. De las 1.065.888 filas descargadas, 533.096 (50,01 %) son duplicados exactos y el identificador `estu_consecutivo` tiene solo 532.792 valores distintos: cada registro aparece dos veces en la tabla del portal. Tras eliminar los duplicados quedan 532.792 estudiantes con identificador único, cifra coherente con la población que presenta la prueba en el calendario A. El hallazgo no habría alterado las medias, pero sí todos los conteos y, en la fase de modelado, habría colocado el mismo estudiante en entrenamiento y en prueba, inflando artificialmente cualquier métrica.

Dos columnas son constantes (`periodo` y `estu_estudiante`) y tres casi constantes, `cole_calendario` (99,58 % A, porque los colegios de calendario B presentan en el periodo 2022-1), `estu_estadoinvestigacion` (99,96 %) y `estu_privado_libertad` (99,95 %). Los códigos y nombres del colegio tienen entre 9.412 y 13.748 niveles y los municipios más de 1.000, mientras que el departamento tiene 33.

Los valores faltantes (Fig. 1) se concentran en `cole_bilingue` (18,0 %) y en el bloque del hogar (4,3 a 6,7 %); los puntajes están completos salvo inglés (0,37 %). El 2,31 % de los estudiantes no respondió ninguna pregunta del cuestionario, el 10,14 % tiene al menos una respuesta faltante y el 89,86 % lo diligenció completo. La ausencia no es aleatoria, puesto que quienes no tienen cuestionario promedian 229,1 puntos frente a 250,6 de quienes sí lo tienen.

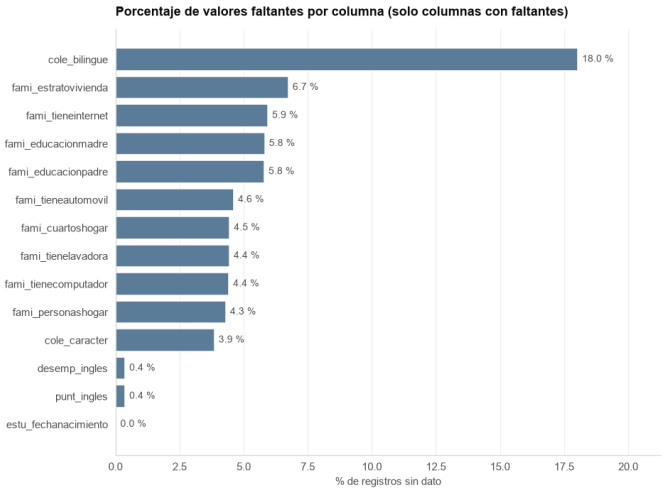


Figura 1. Porcentaje de valores faltantes por columna, para las columnas que tienen al menos uno.

La fecha de nacimiento se convirtió en edad al momento de la prueba, con media de 17,8 años, mediana de 17,2 y el 50 % central entre 16,7 y 18,1 años; solo 81 fechas no pudieron interpretarse y 218 edades quedaron fuera del rango plausible.

V-B. Variable objetivo

El puntaje global tiene media de 250,1, mediana de 247 y desviación de 51,8 puntos; la mitad central de los estudiantes queda entre 210 y 288, el 1 % inferior por debajo de 156 y el 1 % superior por encima de 369. La asimetría de 0,28 y la curtosis de $-0{,}54$ describen una distribución casi simétrica, con una leve cola derecha y colas más ligeras que la normal (Fig. 2), de modo que no hace falta transformar la variable y las métricas de error se leen directamente en puntos.

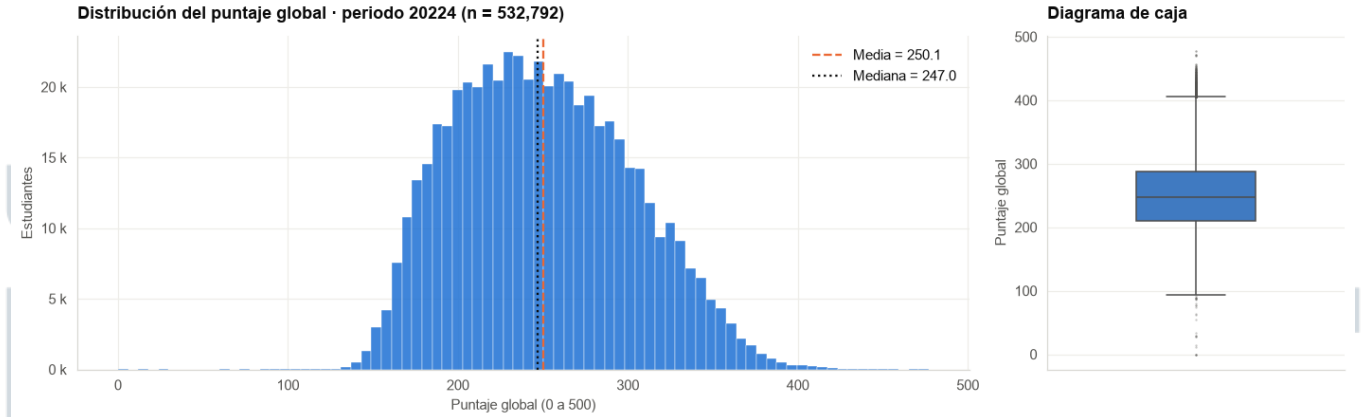


Figura 2. Distribución del puntaje global en el periodo 2022-4 (532.792 estudiantes): histograma con media y mediana, y diagrama de caja.

La fórmula (1) se cumple en el 100 % de los 530.815 registros que tienen las cinco pruebas, con una diferencia máxima de cero puntos, y cada área correlaciona entre 0,91 y 0,92 con el global (0,80 inglés). El puntaje global es por tanto una función determinista de los puntajes por área, y estos quedan excluidos del conjunto de variables explicativas.

V-C. Variables del estudiante

Los hombres promedian 254,1 puntos y las mujeres 246,8, una brecha de 7,3 puntos. La edad es una de las variables más informativas (Fig. 3): los estudiantes de 16 y 17 años promedian 265 puntos, a los 18 el promedio baja a 250,5, a los 19 y 20 a 229,5, entre 21 y 25 a 206,1 y de 26 en adelante a 199,6, una caída de más de 65 puntos que marca trayectorias de extraedad y educación de adultos. El tipo de documento redunda con la edad, la tarjeta de identidad promedia 255,6 y la cédula de ciudadanía 219,4.

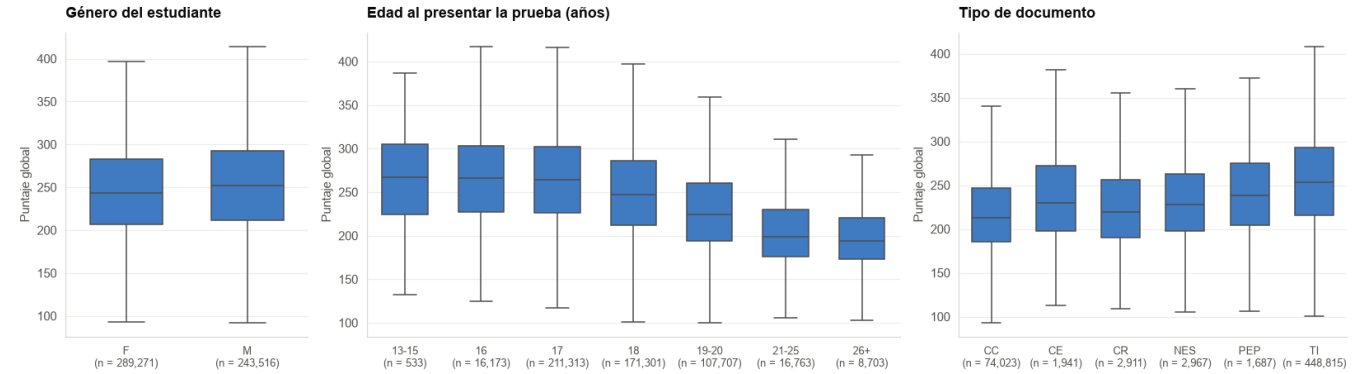


Figura 3. Puntaje global según género, tramo de edad y tipo de documento del estudiante (diagramas de caja sin valores atípicos; n de cada grupo en el eje).

V-D. Variables del hogar

La Tabla III y la Fig. 4 muestran la gradiente socioeconómica. La educación de la madre tiene una relación perfectamente monótona con el puntaje, de 211,2 puntos cuando no tiene ningún nivel educativo a 307,5 cuando tiene posgrado, 96 puntos de diferencia, el contraste más amplio del análisis; la del padre va de 214,5 a 311,9, y su categoría *No sabe* reúne 36.317 estudiantes (6,8 %), reflejo de hogares sin presencia paterna, que promedian 260,7. El estrato sube de 212,6 (*Sin estrato*) a 267,4 (estrato 4) pero cae en los estratos 5 (261,4) y 6 (245,1), que tienen las desviaciones más altas y los grupos más pequeños, un quiebre que apunta a errores de reporte en el cuestionario.

Tabla III
PUNTAJE GLOBAL MEDIO SEGÚN VARIABLES ORDINALES DEL HOGAR

Variable y nivel	n	**Media**
Estrato: Sin estrato	19.781	212,6
Estrato 1	146.333	242,0
Estrato 2	180.091	253,7
Estrato 3	110.254	263,2
Estrato 4	28.092	267,4
Estrato 5	8.448	261,4
Estrato 6	3.879	245,1
Educ. madre: Ninguno	10.260	211,2
Primaria completa	42.124	233,4
Secundaria completa	143.736	249,4
Técnica o tecnológica completa	52.289	268,0
Educación profesional completa	62.318	278,4
Postgrado	11.372	307,5
No sabe	12.638	261,5

UNIVERSIDAD DE LA SALLE

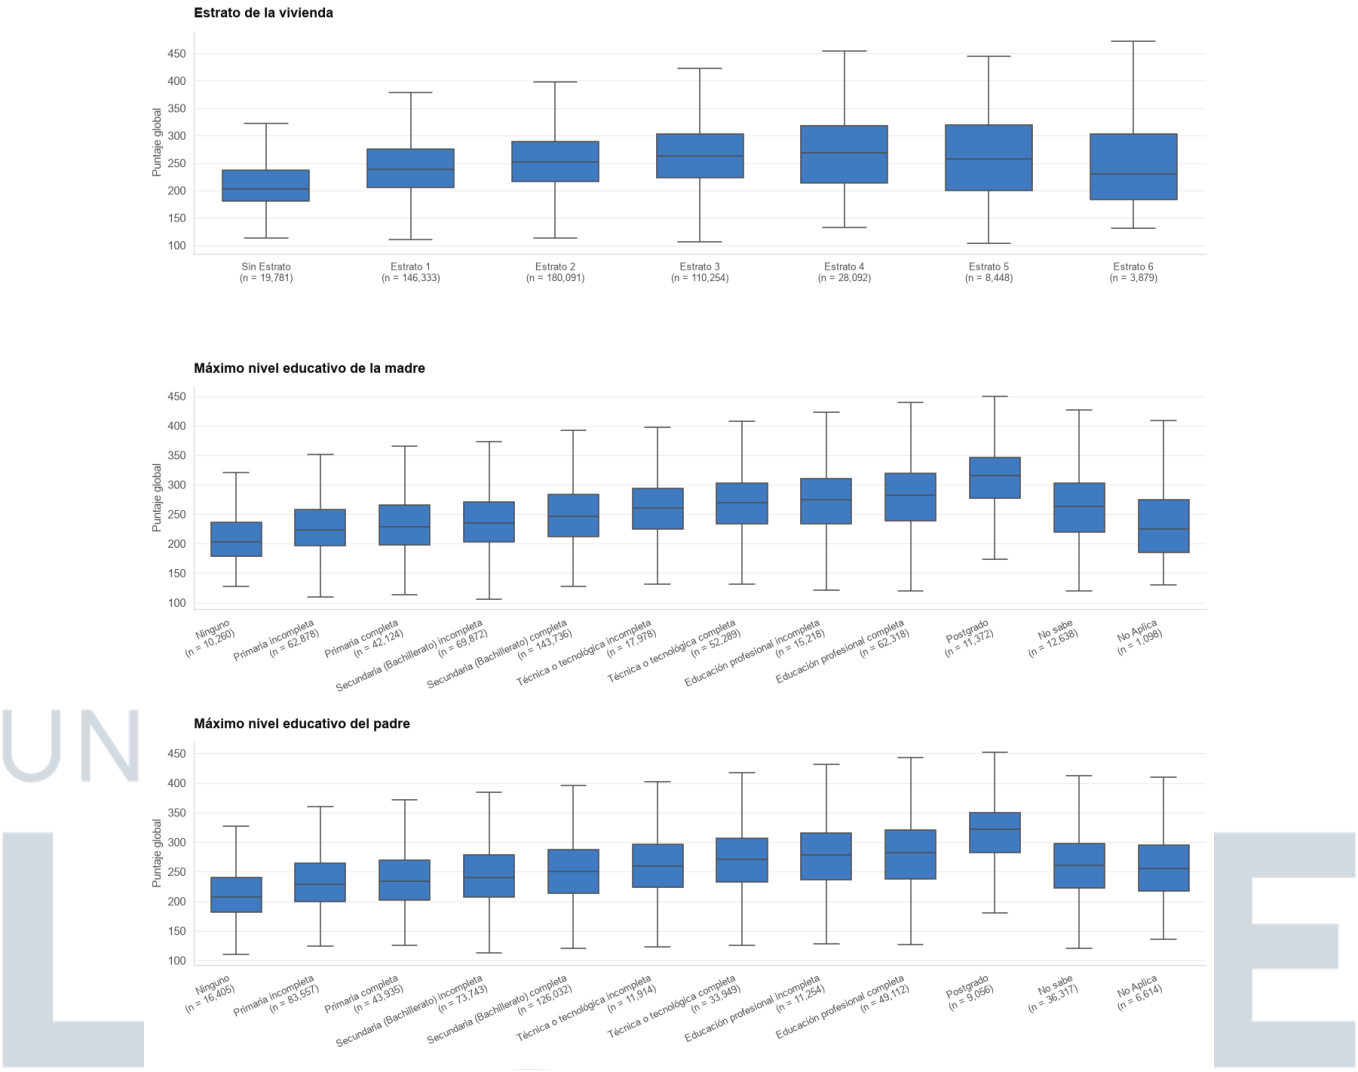


Figura 4. Puntaje global según estrato de la vivienda y máximo nivel educativo de la madre y del padre.

Tener internet (+31,8 puntos) y computador (+31,7) marcan una diferencia muy superior a la del automóvil (+23,6) y la lavadora (+20,8), y en 2022 todavía el 27 % de los hogares declaraba no tener internet. La composición del hogar no es monótona (Fig. 5): el puntaje es máximo en hogares de 3 a 4 personas (257,1) y en viviendas de tres cuartos (255,8), y desciende hacia ambos extremos, hasta 225,0 en hogares de 9 o más personas y 232,3 en viviendas de seis o más cuartos, frecuentes en zonas rurales de bajo ingreso.

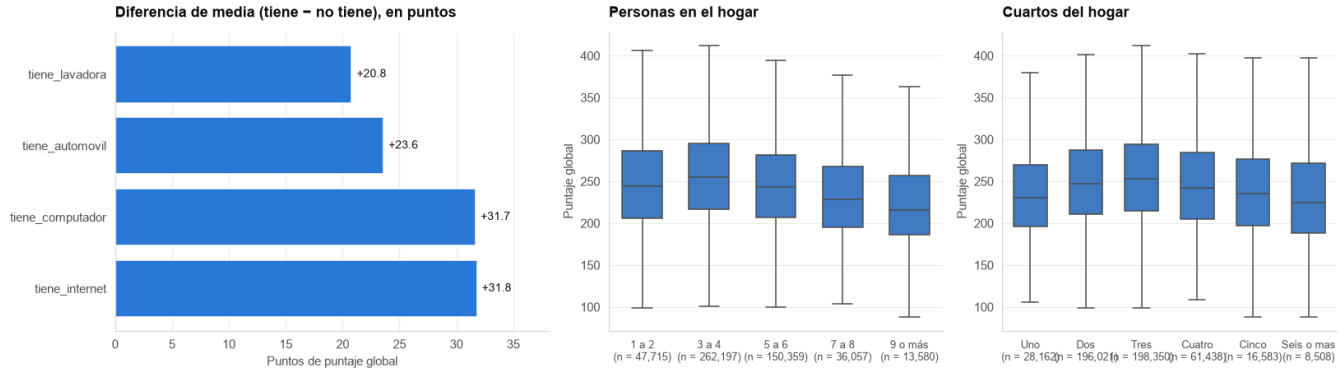


Figura 5. Diferencia de puntaje medio según tenencia de bienes del hogar, y puntaje según personas y cuartos del hogar.

V-E. Variables del colegio

La Tabla IV y la Fig. 6 resumen las variables del colegio. Los colegios no oficiales promedian 272,6 puntos frente a 243,6 de los oficiales (29 puntos), los urbanos 254,6 frente a 228,4 de los rurales (26,2 puntos), y la jornada es la variable con mayor rango: la completa promedia 280,8 mientras que la sabatina (212,7) y la nocturna (210,6) quedan 70 puntos por debajo. El carácter académico (253,9) supera levemente al técnico (243,3). Contra lo esperado, los colegios marcados como bilingües promedian 247,0, por debajo de los no bilingües (252,1), lo que sumado a su 18 % de faltantes hace del indicador una variable poco confiable. Los colegios femeninos (285,5) y masculinos (294,2) superan por mucho a los mixtos (249,0), pero son grupos pequeños compuestos sobre todo por colegios privados.

Tabla IV
PUNTAJE GLOBAL MEDIO SEGÚN VARIABLES DEL COLEGIO

Variable y nivel	n	**Media**
Naturaleza: Oficial	412.313	243,6
No oficial	120.478	272,6
Área: Urbano	441.577	254,6
Rural	91.214	228,4
Jornada: Completa	76.897	280,8
Única	146.360	252,0
Mañana	208.530	248,2
Tarde	49.187	245,5
Sabatina	28.116	212,7
Noche	23.701	210,6
Carácter: Académico	269.918	253,9
Técnico/académico	174.947	248,9
Técnico	58.697	243,3

UNIVERSIDAD DE LA SALLE

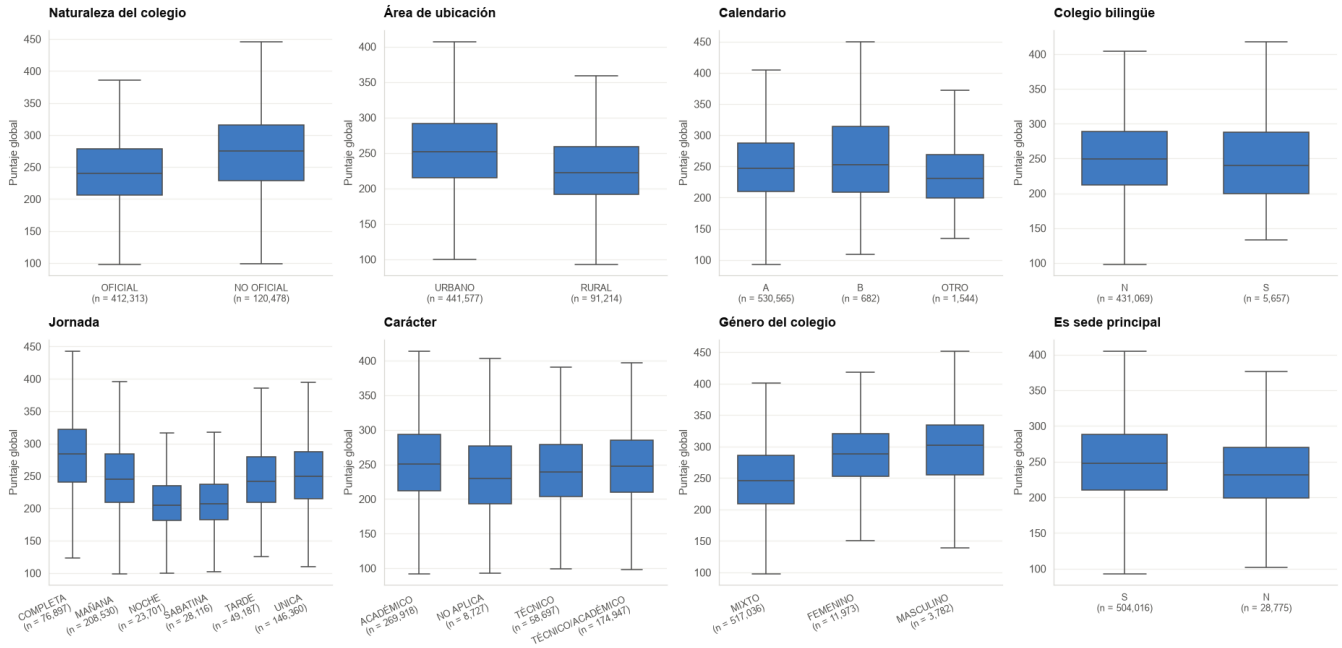


Figura 6. Puntaje global según naturaleza, área, calendario, bilingüismo, jornada, carácter, género y sede del colegio.

El cruce entre naturaleza y área (Tabla V) desenreda ambos efectos. Entre los colegios oficiales la brecha urbano-rural es de 24 puntos, pero entre los no oficiales se invierte: los privados rurales, pocos y en buena parte colegios campestres, promedian 291,1, el valor más alto de las cuatro celdas. Un modelo lineal necesitará un término de interacción entre ambas variables.

Tabla V
PUNTAJE GLOBAL MEDIO Y TAMAÑO SEGÚN NATURALEZA Y ÁREA DEL COLEGIO

	Media		n	
Naturaleza	Rural	Urbano	Rural	Urbano
No oficial	291,1	271,7	5.328	115.150
Oficial	224,5	248,6	85.886	326.427

V-F. Variables geográficas

La brecha regional es grande y ordenada (Fig. 7). Bogotá (270,2), Boyacá (268,6), Santander (267,0) y Cundinamarca (262,8) encabezan la lista; Chocó (206,1), Vaupés (213,7), Amazonas (215,5), Vichada (217,9) y La Guajira (221,5) la cierran. Entre el primero y el último hay 64,1 puntos, más que la diferencia entre colegios oficiales y privados, y solo 11 de los 33 departamentos superan la media nacional de 250,1. Varios departamentos tienen muy pocos estudiantes (Guainía 389, Vaupés 434, San Andrés 577), lo que exige una codificación regularizada.

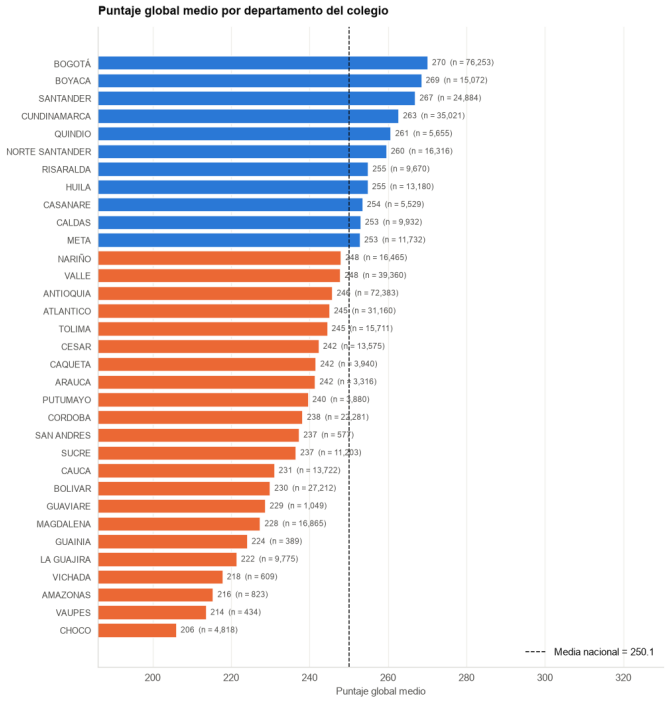


Figura 7. Puntaje global medio por departamento del colegio; en azul los departamentos por encima de la media nacional y en naranja los que están por debajo.

V-G. Correlaciones y ajuste lineal exploratorio

La matriz de correlación de Spearman (Fig. 8) muestra el contraste buscado, los puntajes por área correlacionan entre 0,91 y 0,92 con el global mientras que ninguna variable

explicativa legítima supera 0,35 (Tabla VI). Las variables del hogar están además correlacionadas entre sí (educación de la madre y del padre 0,61; computador e internet 0,48), de modo que miden facetas del mismo nivel socioeconómico.

Tabla VI
CORRELACIÓN DE SPEARMAN DE LAS VARIABLES CANDIDATAS CON EL PUNTAJE GLOBAL

Variable	ρ
Educación de la madre	0,35
Edad	−0,32
Educación del padre	0,32
Tiene computador	0,30
Tiene internet	0,28
Colegio no oficial	0,22
Estrato	0,19
Colegio urbano	0,19
Jornada completa o única	0,19
Tiene automóvil	0,19
Tiene lavadora	0,17
Personas en el hogar	−0,11
Género femenino	−0,07
Colegio bilingüe, cuartos, calendario B	$\lvert\rho\rvert \leq 0{,}01$

UNIVERSIDAD DE LA SALLE

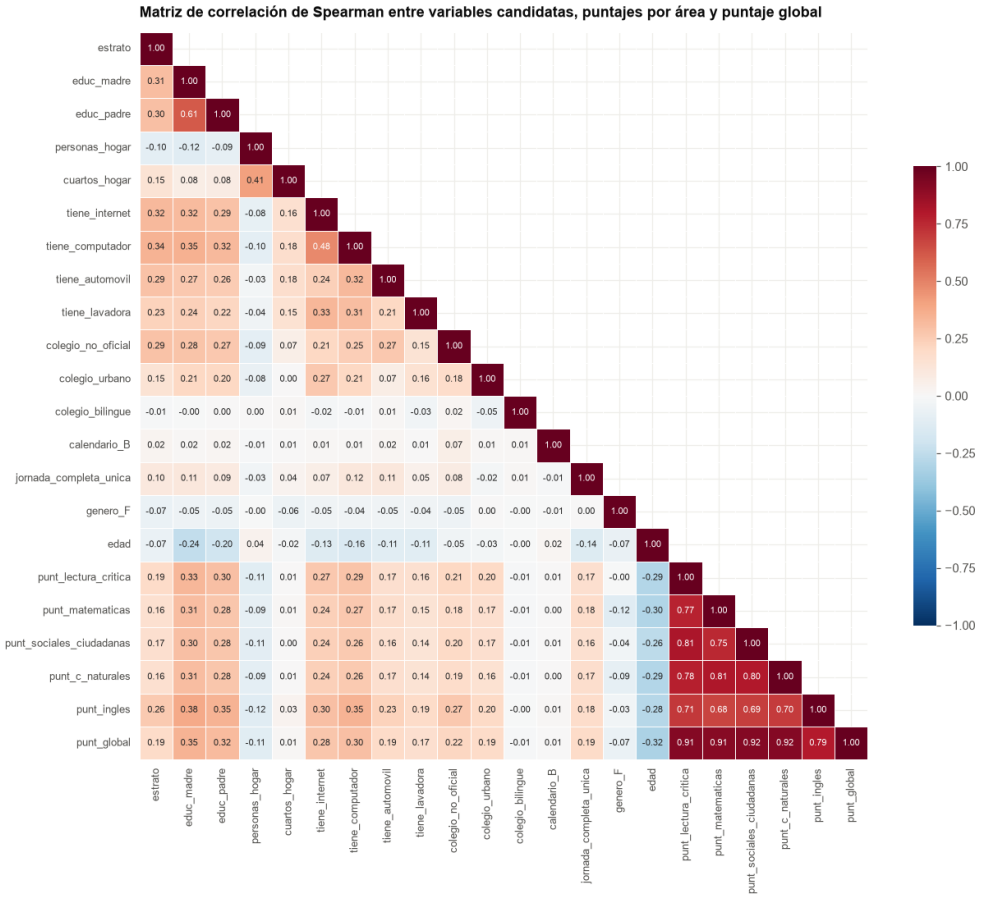


Figura 8. Matriz de correlación de Spearman entre las variables candidatas codificadas, los puntajes por área y el puntaje global.

Una regresión lineal sobre las variables codificadas, con 200.000 filas completas y partición 80/20, alcanza un R^2 de 0,242 y un MAE de 36,5 puntos frente a 42,6 de predecir siempre la media, una reducción del 14 %. Los coeficientes ratifican los resultados bivariados: colegio no oficial (+14,4 puntos), computador (+11,4), jornada completa o única (+11,1), internet (+10,1) y colegio urbano (+9,3) son los mayores efectos por unidad; cada nivel educativo de la madre suma 3,0 puntos y cada año de edad resta 2,9. El estrato queda con un coeficiente casi nulo ($-0{,}56$) porque los bienes del hogar y la educación de los padres absorben su información.

V-H. Hallazgos y decisiones para la fase 2

Los hallazgos anteriores se traducen en las decisiones de preparación de datos e ingeniería de variables de la Tabla VII. Con ellas, el conjunto de trabajo para la fase 2 queda en 532.792 registros y cerca de 22 variables explicativas, con el puntaje global como objetivo.

Tabla VII
HALLAZGOS DEL ANÁLISIS EXPLORATORIO Y DECISIONES PARA LA FASE 2

Hallazgo	**Decisión**
Cada registro aparece dos veces	Eliminar duplicados antes de particionar.
El global es función exacta de las áreas	Excluir `punt_*` por área y `desemp_ingles`.
La ausencia del cuestionario es informativa (21,5 puntos menos)	Conservar faltantes como categoría *no respondió* e indicador de cuestionario incompleto.
Columnas constantes, casi constantes, identificadores y nombres	Descartarlas; conservar departamento y municipio del colegio.
Educación de los padres e internet/computador lideran	Educación como ordinal 0 a 9 con *No sabe* como nivel propio; bienes binarios.
El estrato se quiebra en 5 y 6	Probarlo como nominal o agrupar 4 a 6.
Personas y cuartos en forma de U	Crear personas por cuarto; tratarlas como categóricas.
La edad marca extraedad	Edad numérica e indicador de extraedad; descartar tipo de documento.
Jornada, naturaleza y área con interacción	Nominales más interacción naturaleza $\times$ área.
Indicador bilingüe poco confiable	Descartarlo o conservarlo con *no reportado*.
Brecha regional con departamentos pequeños	*One-hot* o codificación por objetivo suavizada; municipio solo por objetivo.
R^2 lineal de 0,242	Referencia: regresión lineal regularizada; meta de la fase 3: superarla con modelos no lineales.

VI. Conclusiones

- El conjunto *Resultados únicos Saber 11* del periodo 2022-4 es apto para el problema planteado, puesto que es público, con licencia abierta, tiene una variable objetivo continua y bien comportada (media 250,1, desviación 51,8, asimetría 0,28) y reúne, para 532.792 estudiantes, información del hogar, del colegio y de la geografía que existe antes de la prueba.
- La verificación de calidad fue tan importante como el análisis de las variables, dado que la mitad de las filas descargadas eran duplicados exactos y el puntaje global resultó ser una función determinista de los puntajes por área. Ambos hallazgos, de pasarse por alto, habrían producido métricas de modelado ficticias.
- Las tres hipótesis de trabajo reciben respaldo preliminar. El nivel socioeconómico del hogar, en particular la educación de los padres y el acceso a internet y computador, concentra las asociaciones más altas (H1); las características del colegio, sobre todo la jornada y la naturaleza, aportan brechas propias de 29 a 70 puntos y una interacción con el área (H2); y el departamento del colegio introduce una brecha de 64 puntos entre Bogotá y Chocó que ninguna variable individual explica por sí sola (H3).
- Ninguna variable aislada correlaciona más de 0,35 con el puntaje y una regresión lineal aditiva explica el 24,2 % de la varianza con un error absoluto medio de 36,5 puntos. Ese es el punto de partida honesto del proyecto: el modelo de referencia de la fase 2 deberá reproducirlo con la partición definitiva y los modelos de la fase 3 deberán superarlo capturando las relaciones no lineales y las interacciones identificadas.
- Los valores faltantes no son aleatorios, quienes no responden el cuestionario obtienen 21,5 puntos menos, y varias variables ordinales no se comportan como tales (estrato, personas y cuartos del hogar). La estrategia de preparación debe conservar esa información en lugar de imputarla o descartarla, lo que define el plan de limpieza e ingeniería de variables de la siguiente actividad.

Como trabajo futuro inmediato, la fase 2 implementará las doce decisiones de la Tabla VII, construirá la partición definitiva en entrenamiento, validación y prueba, y establecerá el modelo de referencia; las fases 3 y 4 compararán modelos no lineales con ajuste de hiperparámetros, interpretarán el modelo final y comunicarán los resultados. Quedan abiertas la extensión a varios periodos y el uso de información agregada por colegio y municipio como variables de contexto.

Apéndice A
Cuaderno de Google Colab

Todo el desarrollo descrito en este informe se implementó en un único cuaderno de Google Colab titulado *Predicción del puntaje global de la prueba Saber 11 a partir de variables socioeconómicas y del colegio*, que se conserva también en el repositorio del proyecto como `notebooks/01_planteamiento_y_eda.ipynb`. Los segmentos de código reproducidos en las secciones de metodología y resultados corresponden, uno a uno y en el mismo orden, a las celdas de ese cuaderno, y cada uno tiene su archivo espejo en `utils/codes/`.

Cuaderno interactivo disponible en Google Colab

https://colab.research.google.com/

(enlace por actualizar al publicar el cuaderno)

El cuaderno está organizado en doce secciones que siguen el mismo hilo argumental del informe:

- Planteamiento del problema, pregunta de investigación, objetivos, hipótesis y alcance.
- Preparación del entorno e identidad gráfica.
- Carga y descripción del conjunto de datos, con el diccionario de variables.
- Estructura y calidad de los datos: duplicados, columnas constantes, valores faltantes y conversión de tipos.
- La variable objetivo: distribución y verificación de la fórmula del puntaje global.
- Variables del estudiante.
- Variables del hogar.
- Variables del colegio.
- Variables geográficas.
- Correlaciones y ajuste lineal exploratorio.
- Hallazgos y decisiones para la fase 2.
- Conclusiones.

Su ejecución no requiere ninguna instalación ni descarga manual, puesto que el conjunto de datos se obtiene con *kagglehub* desde la copia pública publicada en Kaggle [9], sin necesidad de cuenta, y todas las dependencias vienen preinstaladas en el entorno estándar de Colab. La descarga del archivo Parquet de 31,5 MB toma unos segundos y el cuaderno completo se ejecuta en menos de cinco minutos. La única fuente de aleatoriedad es el muestreo del ajuste lineal exploratorio, gobernado por la semilla `RANDOM_STATE = 42`, de modo que todas las cifras reportadas se reproducen exactamente.

Referencias

[1] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, "CRISP-DM 1.0: Step-by-step data mining guide," The CRISP-DM consortium, Tech. Rep., 2000.

[2] Universidad de La Salle, "Proyecto integrador de ciencia de datos: cronograma de fases, entregables y actividades del aula virtual," Material de clase, asignatura Ciencia de Datos, Maestría en Inteligencia Artificial, Universidad de La Salle, Bogotá, Colombia, 2026.

[3] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA, USA: Addison-Wesley, 1977.

[4] Instituto Colombiano para la Evaluación de la Educación (ICFES), "Guía de orientación Saber 11.° 2022," ICFES, Bogotá, Colombia, 2022. [Online]. Available: https://www.icfes.gov.co/evaluaciones-icfes/saber-11/

UNIVERSIDAD DE LA SALLE

[5] Instituto Colombiano para la Evaluación de la Educación (ICFES), "Resultados únicos Saber 11," Portal Nacional de Datos Abiertos de Colombia, conjunto de datos kgxf-xxbe, licencia CC BY-SA 4.0, 2023. [Online]. Available: https://www.datos.gov.co/Educaci-n/Resultados-nicos-Saber-11/kgxf-xxbe
[6] A. Gaviria and J. H. Barrientos, "Determinantes de la calidad de la educación en Colombia," Departamento Nacional de Planeación, Archivos de Economía, Bogotá, Colombia, Tech. Rep. 159, 2001.
[7] S. M. Chica Gómez, D. M. Galvis Gutiérrez, and A. Ramírez Hassan, "Determinantes del rendimiento académico en Colombia: pruebas ICFES Saber 11°, 2009," *Revista Universidad EAFIT*, vol. 46, no. 160, pp. 48–72, 2010.
[8] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, pp. 1–21, 2012.
[9] A. G. Rubiano Muñoz, "Saber 11 Colombia - Resultados 2022-4," Kaggle, copia en formato Parquet del periodo 2022-4 de *Resultados únicos Saber 11* (ICFES), licencia CC BY-SA 4.0, 2026. [Online]. Available: https://www.kaggle.com/datasets/andyrubiano/saber-11-resultados-2022-4
[10] W. McKinney, "Data structures for statistical computing in Python," in *Proc. 9th Python in Science Conf. (SciPy)*, Austin, TX, USA, 2010, pp. 56–61.
[11] J. D. Hunter, "Matplotlib: A 2D graphics environment," *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.
[12] M. L. Waskom, "seaborn: statistical data visualization," *Journal of Open Source Software*, vol. 6, no. 60, p. 3021, 2021.
[13] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
[14] C. Spearman, "The proof and measurement of association between two things," *The American Journal of Psychology*, vol. 15, no. 1, pp. 72–101, 1904.

UNIVERSIDAD DE LA SALLE