UNIVERSIDAD DE LA SALLE

Facultad de Ingeniería / Maestría en inteligencia artificial

GUÍA TÉCNICA DETALLADA

PROYECTO INTEGRADOR DE CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

Asignatura: Ciencia de Datos

Docente: Fabián Camilo Castro Riveros

Periodo Académico: 20 de octubre – 28 de noviembre de 2026

Propósito del Documento: Esta guía establece los términos de referencia estritos, especificaciones técnicas, algoritmos obligatorios, entregables por fase y rúbricas de evaluación para el desarrollo del Proyecto Integrador. No se permiten interpretaciones ambiguas respecto a los requerimientos de cada entrega.

Bogotá D.C., Colombia

1. Descripción General y Cronograma General

El Proyecto Integrador abarca el ciclo de vida completo de un problema de Ciencia de Datos y Machine Learning: desde el planteamiento del problema de negocio/investigación y la preparación de datos reales, hasta el modelado avanzado (Supervisado, No Supervisado) y la puesta en producción de un **Dashboard Interactivo**.

Fase	Act.	Entregables y Hitos del Aula Virtual	Apertura	Cierre / Entrega	Peso
Fase 1	Act 1	Conformación de equipos y selección del dataset	20 Oct	25 Oct	–
	Act 2	Planteamiento del problema, EDA y propuesta (**Entregable 1**)	26 Oct	**01 Nov**	**20%**
Fase 2	Act 3	Limpieza e ingeniería de variables	03 Nov	08 Nov	–
	Act 4	Partición de datos y Modelo Base / Baseline (**Entregable 2**)	09 Nov	**15 Nov**	**25%**
Fase 3	Act 5	Modelado avanzado (Regresión, Clasificación, Clustering)	16 Nov	19 Nov	–
	Act 6	Evaluación comparativa, optimización e interpretabilidad (**Entregable 3**)	20 Nov	**22 Nov**	**25%**
Fase 4	Act 7	Dashboard Interactivo y narrativa de datos	23 Nov	25 Nov	–
	Act 8	Redacción del Informe Técnico Final	26 Nov	27 Nov	–
	Act 9	Sustentación oral y entrega final del repositorio (**Entregable 4**)	28 Nov	**28 Nov**	**30%**

Cuadro 1: Cronograma detallado de fases, actividades de aula virtual y ponderaciones.

2. Requisitos Estrictos del Conjunto de Datos (Dataset Libre)

El conjunto de datos debe ser de **acceso libre y público**, proveniente exclusivamente de repositorios académicos, institucionales o de investigación reconocidos.

2.1. Repositorios Permitidos

1. **Kaggle Datasets** (Repositorio público con licenciamiento CC o explícito).
2. **UCI Machine Learning Repository** (`https://archive.ics.uci.edu`).
3. **Google Dataset Search** (`https://datasetsearch.research.google.com`).
4. **Zenodo / IEEE DataPort** (Repositorios de investigación abierta).
5. **Portales Oficiales de Datos Abiertos** (ej. Datos.gov.co, Data.gov, Eurostat).

2.2. Restricciones y Especificaciones Obligatorias del Dataset

- Mínimo **600 registros** (filas) de datos limpios.
- Mínimo **5 variables** (columnas) que incluyan combinación de tipos cuantitativos (continuos/discretos) y cualitativos (nominales/ordinales).

- **Versatilidad de Objetivos:** El dataset debe permitir extraer simultáneamente:
  1. Una variable continua para un problema de **Regresión**.
  2. Una variable categórica o categórica derivada para un problema de **Clasificación**.
  3. Múltiples variables cuantitativas para la aplicación de **Clustering / Segmentación No Supervisada**.

3. Especificaciones Detalladas por Fase y Entregable

3.1. FASE 1: Planteamiento del Problema, Descripción y EDA (Entregable 1 – 20%)

Fechas de Trabajo: 20 Oct – 01 Nov — **Fecha Límite de Entrega:** Domingo 01 Noviembre

Requerimientos Técnicos del Informe PDF:

1. **Formulación del Problema y Objetivos:**
   - Contextualización del dominio del problema e impacto potencial de la solución analítica.
   - Formulación de **1 pregunta de investigación principal** y **3 preguntas secundarias**.
   - Objetivos del proyecto (1 General y 3 Específicos) en formato SMART.
2. **Ficha Técnica del Dataset:**
   - Nombre del dataset, repositorio de origen, URL exacta de acceso, fecha de extracción y tipo de licencia libre.
   - Diccionario de datos exhaustivo: Nombre de la columna, tipo de variable (cuantitativa continua/discreta, cualitativa nominal/ordinal), descripción funcional y rango/valores permitidos.
3. **Análisis Exploratorio de Datos (EDA) Exhaustivo:**
   - **Análisis Univariado:** Medidas de tendencia central, dispersión, asimetría y curtosis para variables cuantitativas. Tablas de frecuencias para variables cualitativas.
   - **Análisis Bivariado y Multivariado:** Matriz de correlación (Pearson o Spearman), diagramas de dispersión (*scatter plots*), y pruebas de independencia (χ^2).
   - **Diagnóstico de Calidad de Datos:** Porcentaje exacto de datos faltantes por variable, detección de valores atípicos (*outliers*) mediante regla IQR o Z-score, e identificación de incoherencias o duplicados.

3.2. FASE 2: Preprocesamiento, Ingeniería de Variables y Modelo Base (Entregable 2 – 25%)

Fechas de Trabajo: 03 Nov – 15 Nov — **Fecha Límite de Entrega:** Domingo 15 Noviembre

Requerimientos Técnicos del Cuaderno (Jupyter Notebook / Script Executable):

Limpieza e Imputación de Datos:

- Justificación técnica del tratamiento de valores faltantes (eliminación vs. imputación mediante media, mediana, KNNImputer o IterativeImputer). Prohibido imputar sin analizar el mecanismo de falta (MCAR, MAR, MNAR).
- Tratamiento razonado de valores atípicos (*outliers*) mediante remoción, transformación logarítmica o recorte por percentiles (*winsorization*).

Ingeniería y Transformación de Características:

- Creación de al menos **2 variables derivadas** respaldadas en el conocimiento del dominio.
- Codificación de categóricas (*One-Hot Encoding*, *Target Encoding* u *Ordinal Encoding*) previniendo estrictamente la fuga de datos (*Data Leakage*).
- Escalamiento/Estandarización (*StandardScaler*, *MinMaxScaler* o *RobustScaler*) ajustado únicamente sobre el conjunto de entrenamiento.

Estrategia de Partición de Datos e Imbalance:

- División de datos en **Entrenamiento (70–80%)**, **Validación** y **Prueba (20–30%)**. En clasificación, aplicar división estratificada (*Stratified Split*).

- Tratamiento de desbalance severo de clases si aplica (técnicas SMOTE, ADASYN o ajuste de *class_weight*).

Modelo Base (Baseline):

- Implementación de un modelo de referencia sencillo (Regresión Lineal Simple o Regresión Logística básica / Dummy Classifier) para establecer el umbral mínimo de rendimiento.

3.3. FASE 3: Modelado Avanzado, Clustering, Optimización e Interpretabilidad (Entregable 3 – 25%)

Fechas de Trabajo: 16 Nov – 22 Nov — **Fecha Límite de Entrega:** Domingo 22 Noviembre

En esta fase se deben entrenar, ajustar y evaluar tres bloques de algoritmos analíticos:

1. Modelos de Regresión (Predicción Continua):

- Regresión Lineal Multivariable Regularizada (Lasso, Ridge o ElasticNet).
- Algoritmo basado en árboles o ensambles: *Random Forest Regressor* o *XGBoost / Gradient Boosting Regressor*.

2. Modelos de Clasificación (Predicción Categórica):

- Implementación y comparación de **dos algoritmos distintos** seleccionados entre: K-Nearest Neighbors (KNN), Árboles de Decisión, Random Forest, Máquinas de Soporte Vectorial (SVM) o XGBoost.

3. Modelos de Aprendizaje No Supervisado (Clustering / Segmentación):

- **K-Means Clustering:** Determinación explícita del número óptimo de clústeres (K) mediante el Método del Codo y el Coeficiente de Silueta.
- **Segundo Algoritmo No Supervisado:** Implementación de **DBSCAN** o **Clustering Jerárquico Agglomerative**.
- Análisis e interpretación profiláctica de los clústeres descubiertos y su valor práctico para el problema.

Evaluación de los modelos mediante métricas completas (R^2, RMSE, MAE, Accuracy, Precision, Recall, F1-Score, AUC-ROC, Silhouette Score).

3.4. FASE 4: Dashboard Interactivo, Informe Final y Sustentación (Entregable 4 – 30%)

Fechas de Trabajo: 23 Nov – 28 Nov — **Fecha Límite de Entrega:** Sábado 28 Noviembre

1. Requerimientos Técnicos del Dashboard Interactivo:

El producto principal es una **aplicación web interactiva funcional y desplegada en vivo**.

- **Frameworks Permitidos:** Python/R (**Streamlit**, **Dash**, **Panel**, **Shiny**) o software BI (**Power BI**, **Tableau Public**).
- **Módulos Obligatorios del Dashboard:**
  1. **Filtros Dinámicos:** Controles para segmentar por rangos de fechas, categorías y variables numéricas clave.
  2. **Tarjetas KPI Executivas:** Visualización de indicadores principales de rendimiento de la solución.
  3. **Módulo de Predicción en Vivo:** Interfaz interactiva para ingresar nuevos datos de entrada y obtener la predicción instantánea del modelo supervisado.
  4. **Módulo de Segmentación (Clustering):** Gráfico interactivo de dispersión (2D/3D o espacio PCA) que muestre la distribución de los clústeres y sus perfiles numéricos promedio.

2. Informe Técnico Final y Repositorio Reproducible:

- Documento escrito bajo estructura formal de artículo científico/técnico (Resumen, Introducción, Metodología, Resultados, Discusión, Conclusiones y Trabajo Futuro).

- Repositorio público (GitHub/GitLab) estructurado (`/data`, `/notebooks`, `/src`, `/dashboard`) que incluya el archivo `requirements.txt` o `environment.yml` con las versiones exactas para ejecución inmediata.

3. Sustentación Oral (Sábado 28 Noviembre):

- Exposición técnica oral de **12 minutos** por equipo + **5 minutos de preguntas** directas del docente.
- Demostración **en vivo** del Dashboard Interactivo.

4. Rúbrica General de Evaluación

Cada entregable será evaluado cuantitativamente según los criterios transversales de la Tabla 3.

Criterio de Evaluación	Aspectos Específicos Evaluados	Ponderación
Rigor Metodológico y Justificación de Decisiones	Validez en la formulación del problema, idoneidad del dataset, justificación teórica en la selección de modelos (Regresión, Clasificación, Clustering, MLP) y correcto diseño de la partición de datos.	**35%**
Calidad y Reproducibilidad del Código	Código limpio, estructurado, comentado, libre de fuga de datos (*data leakage*), manejo adecuado de librerías y ejecutable de principio a fin mediante `requirements.txt`.	**25%**
Análisis e Interpretación de Resultados	Profundidad en el diagnóstico de métricas (R^2, F1, Silueta, Pérdida en PyTorch, SHAP), detección/prevención de sobreajuste (*overfitting*) e impacto de negocio.	**25%**
Claridad de la Comunicación y Dashboard	Calidad ejecutiva e interactividad del Dashboard, diseño visual de gráficos, coherencia del informe escrito y solvencia técnica en la sustentación oral.	**15%**

Cuadro 2: Matriz general de evaluación de entregables.

5. Lista de Chequeo para Estudiantes (Checklist de Cumplimiento)

Verifique el cumplimiento estricto de cada ítem antes de cargar su trabajo al aula virtual:

Para la Fase 1 (Entregable 1 – 01 Nov):

- □ ¿El dataset proviene de un repositorio público permitido y NO es un dataset didáctico prohibido?
- □ ¿El dataset contiene más de 600 filas y 5 o más variables de distintos tipos?
- □ ¿El informe o el cuadernillo de Python incluye objetivos SMART, diccionario de variables y análisis EDA completo (univariado, bivariado, correlaciones y calidad de datos)?

Para la Fase 2 (Entregable 2 – 15 Nov):

- □ ¿Se trataron e imputaron los valores faltantes y *outliers* con justificación teórica?
- □ ¿Se crearon al menos 2 variables derivadas y se aplicó encoding/escalamiento sin *data leakage*?
- □ ¿Se dividieron los conjuntos en Train/Val/Test y se estableció el modelo *baseline*?

Para la Fase 3 (Entregable 3 – 22 Nov):

- □ ¿Se implementaron y compararon modelos de Regresión Multivariable y Clasificación?
- □ ¿Se aplicó K-Means (evaluando codo y silueta) junto con un segundo algoritmo de Clustering (DBSCAN o Jerárquico)?
- □ ¿Se diseñó, entrenó y evaluó un Perceptrón Multicapa (MLP) en PyTorch graficando su función de pérdida?
- □ ¿Se realizó la búsqueda de hiperparámetros con Cross-Validation y el análisis de interpretabilidad (SHAP/Feature Importance)?

Para la Fase 4 (Entregable 4 – 28 Nov):

- □ ¿El Dashboard Interactivo incluye filtros dinámicos, tarjetas KPI, simulador de predicciones en vivo y mapa visual de clústeres?

- ☐ ¿El repositorio público contiene el archivo `requirements.txt` garantizando reproducibilidad total?
- ☐ ¿Están preparados todos los integrantes para la presentación oral y demostración en vivo de 12 minutos?

Universidad de La Salle – Facultad de Ingeniería
Docente: Fabián Camilo Castro Riveros